


Memoria 1 Partizioni + MMU + swapping

martedì 11 novembre 2025 15:22

Vediamo ora come gestire la memoria (ovvero come gestire l'address space) : quindi si parte dal binding , andando a vedere gli schemi per farlo (partizionamento dinamico e statico) , poi vedendo la tecnica negli attuali so (paginazione/segmentazione) , poi parlando di memoria virtuale e condivisa ; infine vedremo come gestirla in entrambi i sistemi operativi. Andiamo ora a vedere il **binding** (**Associazione di istruzione e dati ad indirizzi di memoria**) ma prima in generale :



Nel caso più semplice : dato un thread che esegue istruzioni nello stack , si ha la possibilità che vi si arrivi ad istruzioni nell RAM (magari esempio con il branch) ; analogamente per l'accesso ai dati . Questo binding può essere di tre tipi

(condizionamento dell'assegnamento della memoria di lavoro ai processi) :

1. A tempo di compilazione

- La posizione dell'address space del processo è fissa e nota a tempo di compilazione(specifico punto della RAM)
- Il codice è assoluto ed ogni riferimento viene risolto tramite l'indirizzo in memoria
- Per modificare i riferimenti occorre ricompilare

2. A tempo di caricamento

- La posizione della memoria dell'applicazione è fissa (definita quando la lanciamo)
- Quindi il codice è rilocabile (il riferimento viene risolto tramite offset dall'inizio dell'address space)
- La base per l'offset è determinata a tempo di lancio dell'applicazione

3. A tempo di esecuzione

- La posizione in memoria del processo può variare durante esecuzione
- Il codice è rilocabile dinamicamente cioè il riferimento viene risolto per determinare l'indirizzo solo se quel riferimento viene richiesto

4. Indirizzo logico

- Riferimento nel testo nel nostro programma per localizzare istruzione e/o dati (sempre nell'address space)

5. Indirizzo fisico

- Posizione reale in memoria di istruzioni e/o dati
- Indirizzo fisico nella RAM

Nei primi due tipi di binding l'indirizzo fisico e logico coincidono . Mentre per l'ultimo possono non coincidere , ed il mapping a run-time degli indirizzi fisici su indirizzi logici viene fatto dalla **mmu** (**memory management unit**) . Facendo un riepilogo :


Binding a tempo di compilazione/caricamento

- ✓adatto a contesti di esecuzione seriale
- ✓adatto a sistemi batch monoprogrammati
- ✓in entrambi i casi è nota la partizione di memoria fisica riservata per il codice dell'applicazione
- ✓la compilazione e/o il caricamento genera un eseguibile "consapevole" di risiedere in quella data regione di memoria fisica

Binding a tempo di esecuzione

- ✓adatto a sistemi batch multiprogrammati
- ✓adatto a sistemi time-sharing
- ✓ogni processo potrà essere caricato e/o spostato dinamicamente in zone di memoria fisica differenti in modo trasparente alla struttura del codice

Andiamo ora a vedere la struttura basica **MMU** :



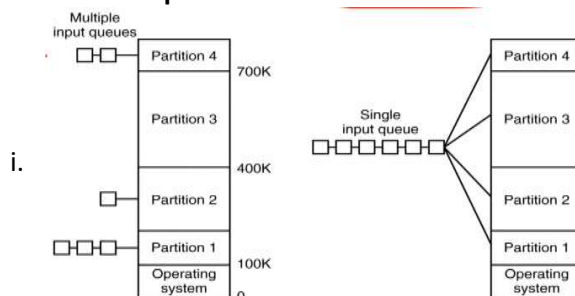
Il registro di rilocalione rappresenta indirizzo al quale incomincia applicazione (indirizzo fisico in RAM). Una domanda sorge: come posso determinare la taglia dell'address space ? Dipende dall'architettura della cpu dove gira : in generale si può avere spazio di indirizzamento di $(2^x)-1$; ma attenzione se spiazamento cade all'esterno dell'address space. Quindi per risolvere questo problema, all'interno della MMU è stato aggiunto altro registro (**registro limite**) , il quale indica il limite massimo all'interno della memoria fisica dove un'applicazione è collocata.



Questo controllo è sempre fatto a run-time, il quale controllo viene effettuato attraverso hardware . Vediamo ora lo scenario nel quale dobbiamo gestire più applicazioni attive :

1. Partizionamento statico a partizioni multiple


- Sistemi multi programmati
- Quindi lo spazio della ram è suddiviso in partizione fisse di taglia uguale o diversa , la quale ognuna ospita un singolo processo
- Ogni processo occupa una partizione intera della ram
- Le partizioni statiche possono portare a **frammentazione interna**
- Il numero massimo di partizioni diminuisce se non c'è swap in/out
- Come si risolve questo problema della taglia delle partizioni? Si fa un mix tra partizioni di taglia piccola e taglia grande
- Allocazione dei processi**



- Quindi vi sono code (sia nel caso di una coda per ogni partizione , sia nel caso di unica coda per tutte le partizioni , la quale riduce la frammentazione esterna)

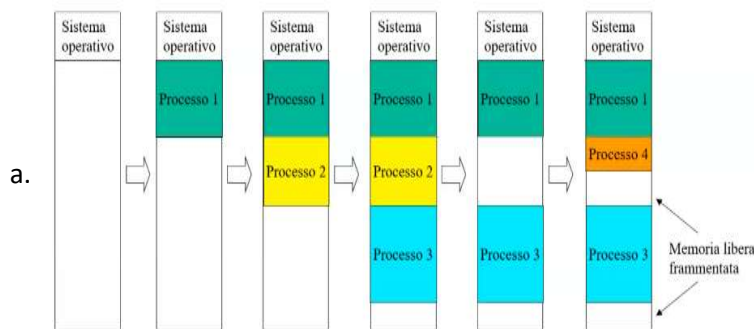
h. Overlay

- Tecnica utilizzata per risolvere il seguente problema: dato un address space di taglia T_1 maggiore della taglia della ram T ; quindi carico in ram solo una parte dell'address space (quello che mi serve)

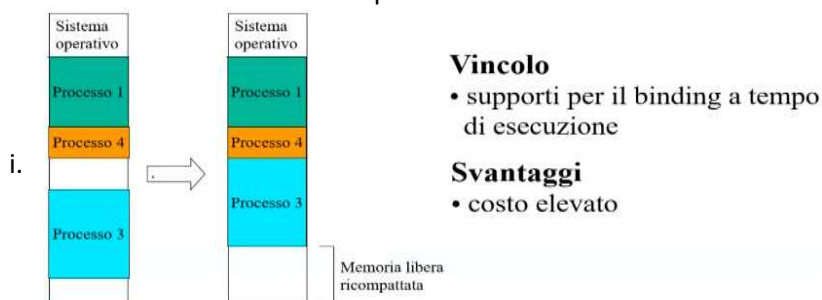


- Questa situazione la gestisce il programmatore
- Questo concetto ha un collegamento con le DLL (librerie caricate dinamicamente)

2. Partizionamento dinamico



- b. Il numero delle partizione e la loro lunghezza è variabile
 c. La memoria allocata è pari a quella dell'address space
 d. L'MMU evita i seguenti bug : accesso ad area di memoria fuori da quella allocata per il processo stesso : il sistema invoca un a trap
 e. Anche qui vi è frammentazione esterna : la memoria è libera ma non contigua . Quindi per evitare questo problema si usa la **ricompattazione** : sposto le zone libere per averne una zona libera di dimensione ampia



- f. Sorge una domanda : date due o più aree di memoria libere quale si sceglie? Vediamolo attraverso degli algoritmi

First fit

- Il processo viene allocato nel primo "buco" disponibile sufficientemente grande
- La ricerca può iniziare sia dall'inizio dell'insieme dei buchi liberi che dal punto in cui era terminata la ricerca precedente

Best fit

- Il processo viene allocato nel buco più piccolo che può accoglierlo
 - La ricerca deve essere effettuata su tutto l'insieme dei buchi disponibili, a meno che questo non sia ordinato in base alla taglia dei buchi
- g. • Questa strategia tende a produrre frammenti di memoria di dimensioni minori, lasciando non frammentate porzioni di memoria più grandi

Worst fit

- Il processo viene allocato nel buco più grande in grado di accoglierlo
- Anche in questo caso la ricerca deve essere effettuata su tutto l'insieme dei buchi disponibili, a meno che questo non sia ordinato in base alla taglia
- Questa strategia tende a produrre frammenti relativamente grandi, utili quindi ad accogliere una quantità di nuovi processi di taglia ragionevole


- h. Il primo è il basico; il secondo ha che nonostante l'applicazione viene inserita nella memoria che calza, vi è sempre una porzione della stessa partizione utilizzata; nel terzo si ha il duale : la partizione rimanente è grande

3. **Swapping**

- a. Tecnica che permette di caricare/scaricare in ram address space solo nel momento che vi è completa inattività

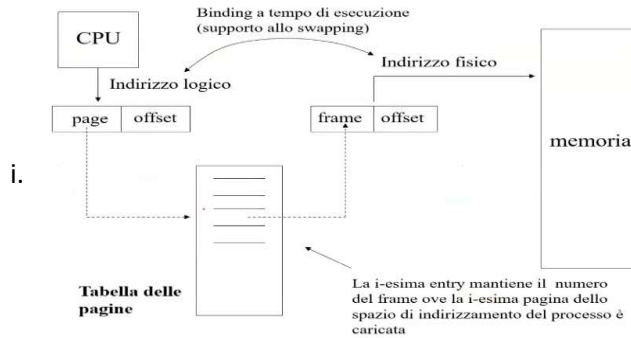
4. **Paginazione**

- a. Ulteriore schema di gestione della memoria (collocazione address space logico all'interno dell'area di lavoro)
- b. Permette di risolvere il problema delle partizioni (statiche / dinamiche) : allocazione nella ram partendo dalla base ed arrivando ad un limite . Quindi **permette di carica in una data zone della ram una data zona dell'address space** (levo la contiguità) . Quindi non ci basta la basica MMU .
- c. **Ogni zona viene chiamata pagina logica** mentre nella ram si hanno **pagine fisiche (frames)**
- d. Non c'è ne frammentazione esterna ne' interna in quanto la taglia della pagina fisica è uguale a quella logica



f. Attenzione se pagina logica è minore di pagina logica : frammentazione esterna possibile

g. Quindi la MMU diventa la seguente :



ii. La tabella delle pagine (tipicamente in ram e puntata da un registro nel processore) viene mandata in setup quando viene fatto il setup dell'address space : viene consultata ogni volta dal processore attraverso il sotto sistema di controllo

iii. Vediamo come ottimizzare : usiamo una cache all'interno del processore TLB (translation lookaside buffer) :

iv. **Mantiene associazioni tra numero di pagina e frame**


v. Permette di bypassare la tabella delle pagine

vi. Se hit ok altrimenti se miss vado a consultare la tabella dei processi e si carica nella TLB

vii. Se più processi più tabelle dei processi




ix. Vediamo ora come è organizzato un indirizzo



2. Si ha quindi protezione della memoria (non si esce da offset della pagina fisica)

3. Vediamo un esempio :



5. Dove si hanno due pagine per il primo bit (0/1) ed 8 possibili entry per via dei 3 bit dell'offset ($8=2^3$)

6. Nelle macchine attuli la dimensione di una pagina e **4kb (2^{12})**

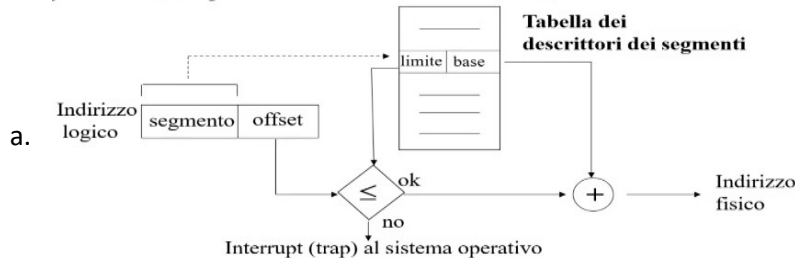
5. Riassumendo (paginazione e dipendenza da hw)

- Setup/gestione della tabella delle pagine via software (di livello kernel) non da luogo ad indipendenza dalla specifica architettura hardware
 - La risoluzione di un miss sul TLB viene infatti effettuata dal microcodice della specifica CPU
 - Questo effettua uno o più accessi alla memoria di lavoro per consultare la tabella delle pagine del processo corrente
 - La struttura della tabella delle pagine (e delle relative informazioni) dipende quindi dalla logica del microcodice
- a.

NOTA BENE:

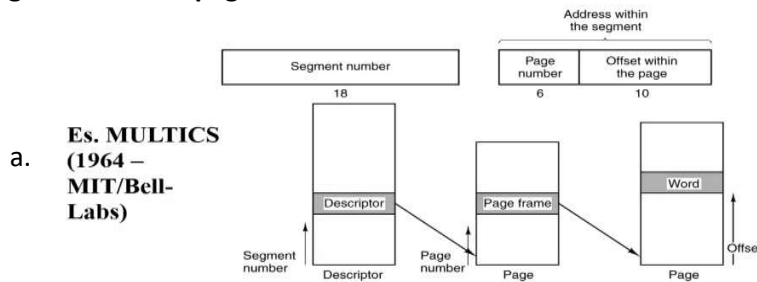
- dato che mantenere la tabella delle pagine via software significa che essa è accessibile tramite indirizzi logici, sarà necessario avere il supporto hardware per mantenere ad ogni istante la corrispondente traduzione fisica
- questo supporto è tipicamente esterno al TLB (ad esempio su x86 è un registro dedicato denominato CR3)

6. Segmentazione




- b. Lo spazio di indirizzamento viene visto come un insieme di segmenti (possibile diversa taglia) scorrelati tra loro.
- c. Nota : la **tabella dei descrittori è simile a quella delle pagine**, ma le entry sono differenti : limite + base (nella RAM), con eventuali informazioni di protezione
- d. Attenzione alla generazione dell'indirizzo fisico (se ok si calcola altrimenti lancio una trap)
- e. Nota : entrambe se prese da sole non bastano!!

7. Segmentazione e paginazione




- b. Address space è insieme di segmenti i quali sono a loro volta suddivisi in pagine : si risolve frammentazione esterna
- c. Vediamolo come funziona sui processori attuali :
- Nella tabella dei segmenti vi è offset della memoria logica : quindi per avere la posizione dell'istruzione si somma la l'indirizzo base + offset -> **indirizzo lineare**
 - Se non specificato si intende DS(Data segment) altrimenti si usa il CS(Code segment)**


1. In dettaglio




2.




- d. Quindi combinando queste due tecniche si ha ulteriore vantaggio : **condivisione della memoria principale**, evitando il problema di avere due processi che puntano alla stessa entry in ram . In dettaglio



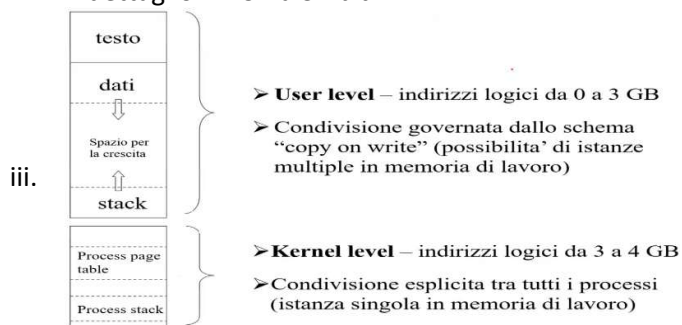
- e. Attenzione al bit **copy on write** il quale bit è di protezione , quindi vediamo un esempio (si fanno copie private)



- f. La paginazione quindi ci dà ulteriore vantaggio ovvero : la condivisione della zona kernel (determinati set di indirizzi logici)

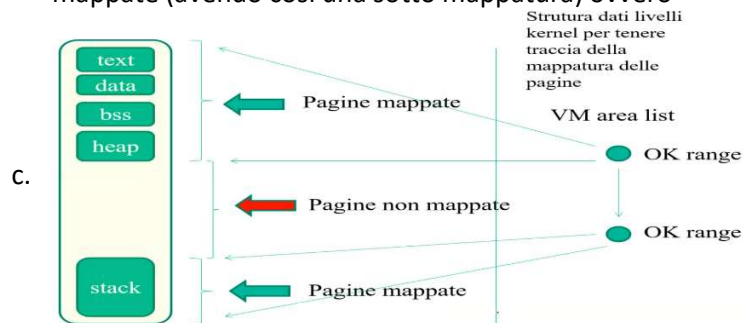


- ii. In dettaglio LINUX a 32 bit

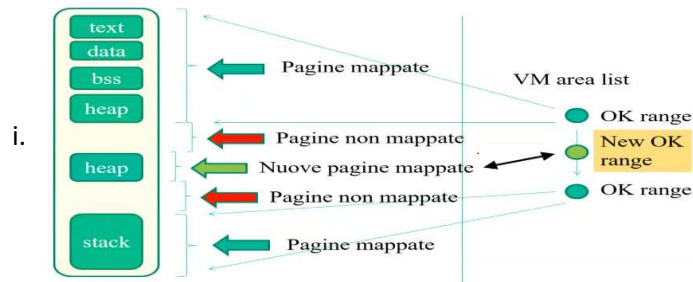


8. Struttura interna address space


- a. Chiaramente se indirizzamento lineare a X bit si hanno massimo 2^X locazioni , le quali non vengono usate tutte in un determinato momento
- b. Attenzione però **alla mappatura dell'address space** ovvero ci possono essere zone non mappate (avendo così una sotto mappatura) ovvero



- d. Dove la VM area list rappresenta l'elenco delle zone correntemente mappate
- e. Quindi si potrebbe avere una situazione del genere (dopo aver mappato delle pagine)



f. In generale quindi su un so moderno si ha che



Materializzata in RAM: la corrispettiva entry della tabella delle pagine mantiene valide informazioni di posizionamento in RAM della pagina

Transizioni legata alla **Memoria Virtuale**

- ii. Possibile che una pagina mappata sia solo presenti nell'address space e per renderla mappata la dobbiamo materializzare in ram ; oppure pagina presente solo in address space ma non in RAM (swap out)